

TP. Hồ Chí Minh, ngày 27 tháng 08 năm 2026

ĐỀ CƯƠNG CHI TIẾT TIỂU LUẬN TỐT NGHIỆP

1. Tên đề tài

Nghiên cứu cải tiến TickNets bằng cơ chế attention CBAM cho bài toán phân loại ảnh.

2. Sinh viên thực hiện:

Sinh Viên Thực Hiện : **CHU TOÀN ĐỨC**

MSSV : **22130047**

Lớp : **DH22DTC**

Khoa : **CÔNG NGHỆ THÔNG TIN**

Niên Khóa : **2022 -2026**

Số Điện Thoại : **0933454194**

3. Giảng viên hướng dẫn: TS. NGUYỄN VĂN DŨ

4. Phát biểu bài toán:

Phân loại hình ảnh là một trong những bài toán cơ bản của thị giác máy tính. Bài toán được phát biểu như sau: cho một hình ảnh đầu vào, cần xác định hình ảnh đó thuộc lớp nào trong một tập lớp cho trước.

Các mạng nơ-ron tích chập hiện đại như ResNet, MobileNet, ShuffleNet, EfficientNet đã đạt độ chính xác cao trên nhiều bộ dữ liệu, nhưng vẫn còn hạn chế về khả năng tập trung vào vùng đặc trưng quan trọng và chi phí tính toán khi triển khai trên thiết bị di động, hệ thống nhúng.

TickNets là một họ mạng CNN siêu nhẹ sử dụng khối Full-Residual Point-Depth-Point và xương sống co giãn kênh hình dấu tích, cho phép giảm đáng kể số tham số và FLOPs . Tuy nhiên, TickNets hiện mới tích hợp cơ chế chú ý theo kênh Squeeze-and-Excitation ở bên trong khối FR-PDP và chưa khai thác đầy đủ các dạng chú ý theo không gian và phân cấp .

Vì vậy, bài toán đặt ra trong tiểu luận là: nghiên cứu, đề xuất và đánh giá một kiến trúc TickNet-small kết hợp cơ chế chú ý CBAM phân cấp cho bài toán phân loại hình ảnh trên các bộ dữ liệu chuẩn như CIFAR-10 và PlantVillage.

5. Mục tiêu của đề tài:

Xây dựng và mô tả chi tiết kiến trúc mạng nơ-ron tích chập siêu nhẹ TickNet-small sử dụng khối FR-PDP và cơ chế chú ý SE nội khối .

Đề xuất cơ chế chú ý phân cấp bằng cách giữ SE nội khối FR-PDP và chèn mô-đun CBAM (CAM + SAM) tại hai điểm nổi chiến lược: sau FR-PDP-5 và sau FR-PDP-10, hình thành mô hình TickNet-small CBAM-Hook.

Hiện thực hoá các mô hình đối chứng SE Baseline, CBAM-Local, CBAM-Hook bằng PyTorch trong môi trường thực nghiệm trên nền tảng Kaggle với GPU T4.

Đánh giá và so sánh hiệu năng phân loại ảnh của các mô hình trên hai bộ dữ liệu CIFAR-10 ảnh nhỏ 32×32 và PlantVillage gồm ảnh lá cây khỏe mạnh và bị bệnh, được chuẩn hóa về kích thước 224×224 thông qua các độ đo Accuracy, Precision, Recall, F1-score, AUC, đồng thời phân tích Confusion Matrix và đường cong ROC.

Sử dụng Grad-CAM để trực quan hóa các vùng đặc trưng có đóng góp vào quyết định dự đoán của từng mô hình, từ đó hỗ trợ phân tích định tính và đối chiếu với các kết quả đánh giá định lượng của SE Baseline, CBAM-Local và CBAM-Hook.

6. Nội dung của đề tài:

Các nội dung cần nghiên cứu, thử nghiệm:

- Nghiên cứu tổng quan các công trình liên quan đến bài toán phân loại hình ảnh, từ các kiến trúc CNN hiện đại đến các mạng CNN gọn nhẹ như MobileNet, ShuffleNet, ShuffleNetV2, GhostNet, EfficientNet. Khảo sát các cơ chế chú ý SE, CBAM và kiến trúc TickNets làm cơ sở cho hướng cải tiến của đề tài.
- Nghiên cứu chi tiết kiến trúc TickNets: khối FR-PDP, xương sống tick-shape co giãn kênh, cơ chế lan truyền đặc trưng và TickNet-small .
- Nghiên cứu các cơ chế chú ý trong CNN: SE, CBAM trong mạng tích chập sâu.

- Đề xuất kiến trúc TickNet-small CBAM-Hook với cơ chế chú ý phân cấp: giữ SE nội khối FR-PDP và chèn CBAM ngoại khối tại hai hooking points sau FR-PDP-5 và FR-PDP-10.
- Mô tả bài toán và hiện thực thực nghiệm: lựa chọn và mô tả chi tiết các bộ dữ liệu CIFAR-10 và PlantVillage, xây dựng pipeline tiền xử lý và tăng cường dữ liệu phù hợp với từng loại ảnh .
- Xây dựng, huấn luyện và so sánh ba mô hình đối chứng (SE Baseline, CBAM-Local, CBAM-Hook) trên môi trường Kaggle, GPU T4, sử dụng framework PyTorch.
- Trong cấu hình thực nghiệm, cơ chế SE nội khối sử dụng tỷ lệ giảm kênh $r=16$, trong khi CBAM tại các điểm Hook sử dụng tỷ lệ giảm $r=8$. Kích thước kernel của mô-đun SAM được điều chỉnh theo kích thước ảnh, với kernel 3×3 cho CIFAR-10 và 7×7 cho PlantVillage.
- Đánh giá kết quả thực nghiệm bằng các độ đo Accuracy, Precision, Recall, F1-score, ROC/AUC và Confusion Matrix, đồng thời phân tích sự khác biệt giữa các chiến lược tích hợp CBAM, đánh giá giả thuyết kiến trúc về khả năng chống chéo xử lý không gian giữa DWConv và SAM, và so sánh hiệu quả của CBAM-Local với CBAM-Hook trên từng bộ dữ liệu.
- Áp dụng Grad-CAM để trực quan hoá bản đồ nhiệt chú ý của từng mô hình trên các mẫu ảnh điển hình, từ đó rút ra nhận xét về hành vi học đặc trưng của mô hình đề xuất.
- Đưa ra kết luận, kiến nghị và các hướng phát triển tiếp theo.

7. Thời gian thực hiện: học kỳ 3, năm học 2025 - 2026.

8. Sản phẩm của đề tài:

Các sản phẩm chính của đề tài bao gồm:

- Bản trình bày tiểu luận đầy đủ cơ sở lý thuyết về TickNets, cơ chế chú ý SE và CBAM, phân tích bài toán phân loại hình ảnh và mô hình đề xuất TickNet-small CBAM-Hook.

- Mã nguồn và kịch bản tiền xử lý, tăng cường dữ liệu, huấn luyện và đánh giá mô hình trên hai bộ dữ liệu CIFAR-10 (32×32, 10 lớp) và PlantVillage (224×224, 38 lớp).
- Bộ kết quả thực nghiệm gồm log huấn luyện, bảng so sánh Accuracy, Precision, Recall, F1-score, Confusion Matrix, đường cong ROC và chỉ số AUC cho ba mô hình SE Baseline, CBAM-Local và CBAM-Hook trên mỗi bộ dữ liệu.
- Các bản đồ nhiệt Grad-CAM minh họa vùng chú ý của từng mô hình trên các ảnh tiêu biểu, dùng để giải thích và minh họa trực quan cho phân tích kết quả.

9. Tài liệu tham khảo:

- [1] T. T. Nguyen and T. P. Nguyen, “Efficient tick-shape networks of full-residual point-depth-point blocks for image classification,” *Neurocomput.*, vol. 596, p. 127942, Sep. 2024, doi: 10.1016/j.neucom.2024.127942.
- [2] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “ImageNet Classification with Deep Convolutional Neural Networks,” in *Advances in Neural Information Processing Systems*, Curran Associates, Inc., 2012.
- [3] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 770–778. doi: 10.1109/CVPR.2016.90.
- [4] M. Tan and Q. Le, “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks,” in *Proceedings of the 36th International Conference on Machine Learning*, 2019, pp. 6105–6114.
- [5] A. G. Howard *et al.*, “MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications,” arXiv preprint arXiv:1704.04861, 2017.
- [6] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, “MobileNetV2: Inverted Residuals and Linear Bottlenecks,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2018, pp. 4510–4520. doi: 10.1109/CVPR.2018.00474.
- [7] A. Howard *et al.*, “Searching for MobileNetV3,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2019, pp. 1314–1324. doi: 10.1109/ICCV.2019.00140.
- [8] J. Hu, L. Shen, and G. Sun, “Squeeze-and-Excitation Networks,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2018, pp. 7132–7141. doi: 10.1109/CVPR.2018.00745.
- [9] X. Zhang, X. Zhou, M. Lin, and J. Sun, “ShuffleNet: An Extremely Efficient Convolutional Neural Network for Mobile Devices,” in *Proceedings of the IEEE*

- Conference on Computer Vision and Pattern Recognition*, 2018, pp. 6848–6856. doi: 10.1109/CVPR.2018.00716.
- [10] N. Ma, X. Zhang, H.-T. Zheng, and J. Sun, “ShuffleNet V2: Practical Guidelines for Efficient CNN Architecture Design,” in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018, pp. 116–131. doi: 10.1007/978-3-030-01264-9_8.
- [11] K. Han, Y. Wang, Q. Tian, G. Jianyuan, C. Xu, and C. Xu, “GhostNet: More Features from Cheap Operations,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020, pp. 1580–1589. doi: 10.1109/CVPR42600.2020.00165.
- [12] A. Vaswani *et al.*, “Attention Is All You Need,” in *Advances in Neural Information Processing Systems*, 2017, pp. 5998–6008.
- [13] Sanghyun Woo, Jongchan Park, Joon-Young Lee, and In So Kweon, “CBAM: Convolutional Block Attention Module,” in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018, pp. 3–19. doi: 10.1007/978-3-030-01234-2_1.
- [14] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization,” *Int. J. Comput. Vision*, vol. 128, no. 2, pp. 336–359, 2020, doi: 10.1007/s11263-019-01228-7.
- [15] Sharada P. Mohanty, David P. Hughes, and Marcel Salathé, “Using Deep Learning for Image-Based Plant Disease Detection,” *Frontiers in Plant Science*, vol. 7, p. 1419, 2016, doi: 10.3389/fpls.2016.01419.
- [16] W. Luo, Y. Li, R. Urtasun, and R. Zemel, “Understanding the Effective Receptive Field in Deep Convolutional Neural Networks,” in *Advances in Neural Information Processing Systems*, Curran Associates, Inc., 2016, pp. 4898–4906.
- [17] Adam Paszke *et al.*, “PyTorch: An Imperative Style, High-Performance Deep Learning Library,” in *Advances in Neural Information Processing Systems*, 2019, pp. 8024–8035.
- [18] A. Krizhevsky, “Learning Multiple Layers of Features from Tiny Images,” University of Toronto, Toronto, ON, Canada, Technical Report, 2009.

Giảng viên hướng dẫn
(Ký và ghi rõ họ tên)

Sinh viên thực hiện
(Ký và ghi rõ họ tên)